Rakamin Academy

Data Cleansing for Machine Learning

Rakamin Trial Class

Saya

Universiteit Leiden

Master of Science

Leiden University (2017-2019)

Focused on application of theoretical machine learning & reinforcement learning

bukalapak

Senior Data Scientist

Bukalapak (2020 - present)

Pararawendy Indarjo

Email : pararawendy19@gmail.com

Linkedin : https://www.linkedin.com/in/pararawendy-indarjo/

Blog : medium.com/@pararawendy19

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Rakamin Academy

Sesi ini:

1. Mengapa data perlu dipreproses?
2. *Missing data*
3. *Duplicated data*
4. *Outliers*
5. *Feature encoding*
6. QnA

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Hands-On Required :

Hands - On :

Hands-On - Data Cleansing.ipynb

Dataset :

1. **botak.csv**

Klik disini untuk mengakses folder Database

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Rakamin Academy

Mengapa Data perlu Diprepproses?

Kebersihan data adalah sebagian dari sukses

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Rakamin Academy

Seberapa kotorkah data-data di dunia nyata? Sangat kotor!

Contoh penyebab ketidakbersihan data:

- Jenis input yang tidak wajib
- User asal/salah mengisi data
- Kesalahan implementasi *tracker* data/*engineering* mistakes
- *Scammer, abuser*
- Etc...

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Ekspektasi :)

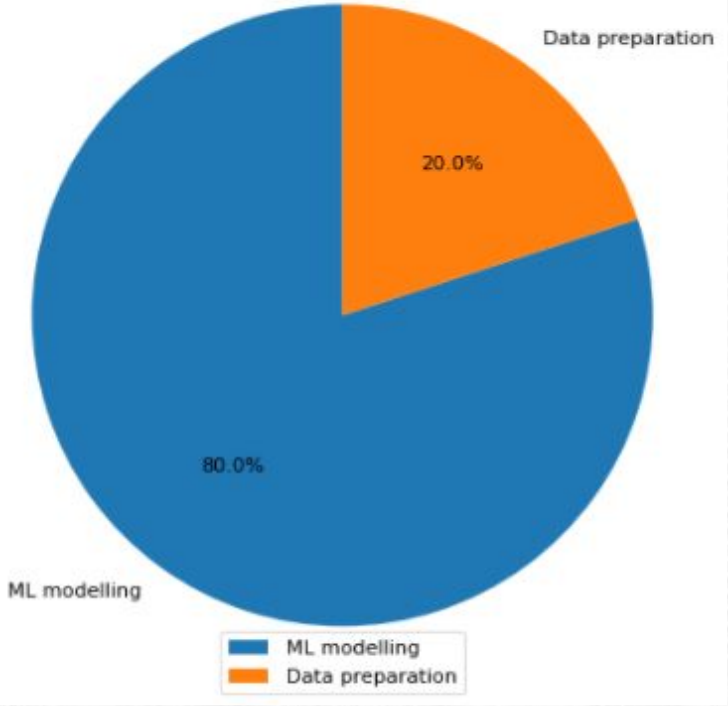

Realita :(

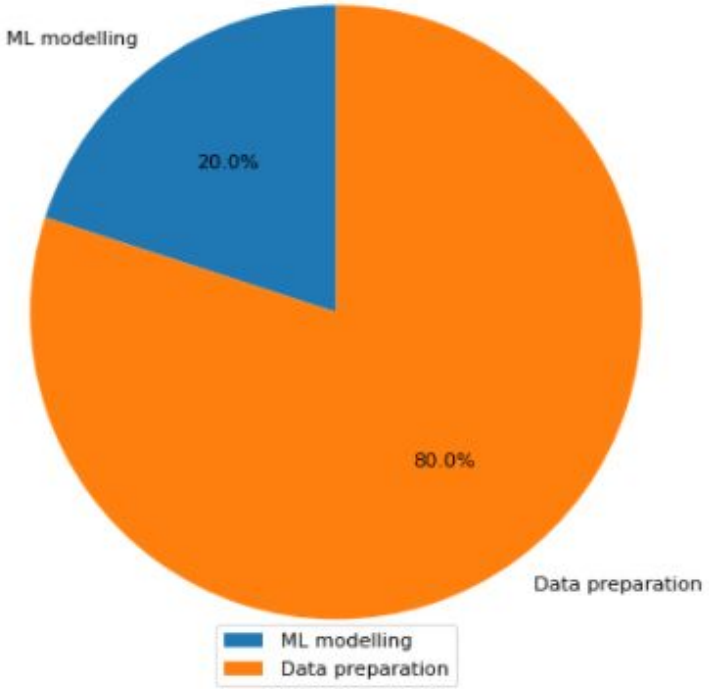

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Rakamin Academy

Data Pre-processing

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Dataset

botak.csv

- **Deskripsi**:

  Dataset sintetik. Memprediksi peluang botaknya seseorang dari beberapa atribut mengenai orang tersebut.

- **Data**:

  Setiap baris mewakili satu orang, setiap kolom berisi atribut orang tersebut.

**ilustrasi tidak ada hubungannya dengan data*

Photo of bald dirty mad man on gray background

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Rakamin Academy

Missing Data

1: Data yang Hilang

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Berapa banyak data yang hilang?

```
df.isna().sum()
```

```
umur              0
jenis_kelamin     9
pekerjaan        67
gaji             23
is_menikah        0
is_keturunan     15
berat            39
tinggi            0
sampo            57
is_merokok        0
pendidikan        0
botak_prob        0
dtype: int64
```

Cara mengecek jumlah nilai yang hilang pada dataframe:

- `df.isna().sum()`

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Teknik #1: Hapus (drop) baris-baris dengan data yang hilang

Rakamin Academy

Ketika kita punya cukup banyak data dan jumlah data yang hilang tidak signifikan, biasanya cukup hapus baris-baris dengan data yang hilang.

```
df = df.dropna()
```

```
df.dropna(inplace=True)
```

Penghapusan dapat dilakukan dengan fungsi `df.dropna()`. Kode di atas menunjukkan contoh 2 cara berbeda menggunakan `df.dropna()`.

Berikut penjelasan untuk 2 parameter yang dipakai di atas:

- `inplace`: Nilai `True` atau `False`. Apabila `True`, tidak mengembalikan dataframe baru tapi langsung menghapus di dataframe awal.

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Teknik #2: Isi data-data yang kosong/Imputation (Numeric)

Ketika kita tidak mau menghapus satu pun baris data, kita bisa mengisi kekosongan data secara manual.

Kita isi dengan apa? Biasanya ada 2 hal yang dipertimbangkan:

- Konteks masalah: nilai apa yang paling masuk akal?
- Performa model ML: nilai apa yang menghasilkan performa model tertinggi?

Pengisian dapat dilakukan dengan fungsi `df.fillna()`

Find out in the Bootcamp :)

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Duplicated Data

2: Data yang Sama

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Berapa banyak data yang duplikat?

```
1 df.duplicated().sum()
```

```
0
```

Pengecekan jumlah nilai yang duplikat pada dataframe dapat dilakukan dengan `df.duplicated().sum()`.

Ketika kita yakin kita tidak memerlukan baris-baris duplikat, biasanya cukup hapus baris-baris tersebut.

```
df = df.drop_duplicates()
```

```
df.drop_duplicates(inplace=True)
```

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Outliers

3: Data yang Berbeda (jauh)

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Rakamin Academy

Outlier itu apa?

Outlier adalah data point (baris) yang nilainya ekstrim/jauh berbeda dari data-data lain pada umumnya. Bisa muncul dari:

- Kesalahan pada pengambilan data
- Keberadaan individu-individu yang ‘spesial’

Kenapa outlier jadi masalah?

Karena dapat menyebabkan model machine learning kita berperforma buruk

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Menghapus outlier berdasarkan *IQR (inter quartile range)*

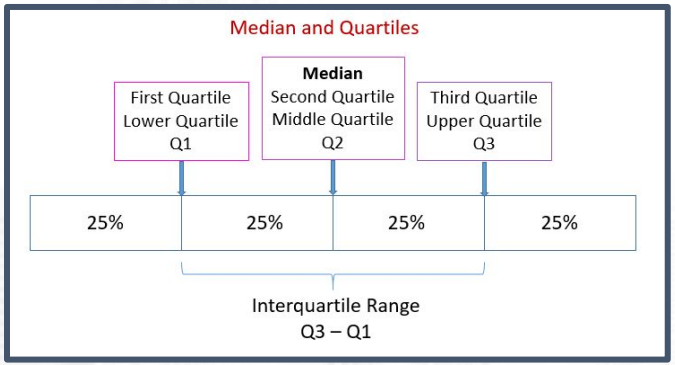

IQR: lebar Q3-Q1

Outlier: Lebih ekstrim dari 1.5 IQR dari Q1 atau Q3

```
1 Q1 = df['umur'].quantile(0.25)
2 Q3 = df['umur'].quantile(0.75)
3 IQR = Q3 - Q1
4 low_limit = Q1 - (1.5 * IQR)
5 high_limit = Q3 + (1.5 * IQR)
6 filtered_entries = ((df['umur'] >= low_limit) & (df['umur'] <= high_limit))
7 df = df[filtered_entries]
```

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Menghapus outlier berdasarkan *IQR*

```
1 Q1 = df['umur'].quantile(0.25)
2 Q3 = df['umur'].quantile(0.75)
3 IQR = Q3 - Q1
4 low_limit = Q1 - (1.5 * IQR)
5 high_limit = Q3 + (1.5 * IQR)
6 filtered_entries = ((df['umur'] < low_limit) | (df['umur'] > high_limit))
7 df = df[filtered_entries]
```

Kode di atas menunjukkan cara menghapus baris berdasarkan outlier di kolom `umur` menggunakan IQR. Berikut penjelasannya:

1. Hitung Q1
2. Hitung Q3
3. Hitung IQR
4. Hitung batas bawah untuk outlier
5. Hitung batas atas untuk outlier
6. Buat filter `boolean` berdasarkan apakah nilai di bawah batas bawah atau di atas batas atas
7. Pakai filter untuk menghapus baris-baris outlier

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Feature Encoding

Mengakomodasi feature categorical

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Feature Encoding itu apa?

Feature Encoding **adalah proses mengubah feature categorical menjadi feature numeric.**

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Data Besaran Penghasilan dari Survei Abhal^2

Gender	Pendidikan	Pekerjaan	Penghasilan (juta)
Laki-laki	S1	SWASTA	7
Laki-laki	SMA	PNS	13
Perempuan	S1	PNS	15
Laki-laki	S2	FREELANCE	24
Perempuan	S3	PNS	17
Perempuan	S1	SWASTA	23
Perempuan	SMA	FREELANCE	12

Pertanyaan

Bagaimana cara mengubah fitur dalam bentuk STRING menjadi angka?

- Sebab Python hanya ‘mengerti’ fitur numerik untuk membangun model

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Teknik #1: Label Encoding

Label Encoding adalah perubahan feature categorical menjadi numeric dengan memberikan angka yang berbeda bagi masing-masing nilai unik

```
mapping_gender = {
    'Laki-laki': 0,
    'Perempuan': 1
}
df['gender'] = df['gender'].map(mapping_gender)

mapping_pendidikan = {
    'SMA': 0,
    'S1': 1,
    'S2': 2,
    'S3': 3
}
df['pendidikan'] = df['pendidikan'].map(mapping_pendidikan)
```

	gender	pendidikan	pekerjaan	penghasilan
0	0	1	SWASTA	7
1	0	0	PNS	13
2	1	1	PNS	15
3	0	2	FREELANCE	24
4	1	3	PNS	17
5	1	1	SWASTA	23
6	1	0	FREELANCE	12

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Lalu bagaimana dengan kolom ‘pekerjaan’?

Teknik #2: One-hot Encoding

One-hot encoding adalah perubahan feature categorical menjadi numeric dengan menjadikan masing-masing nilai unik feature tersendiri

```
1 pd.get_dummies(df['pekerjaan'], prefix='kerja')
```

Kode di atas menunjukkan cara melakukan one-hot encoding pada kolom `pekerjaan` menggunakan `get_dummies()`. Berikut penjelasannya:

1. Parameter pertama adalah kolom yang ingin di one-hot encoding (`pekerjaan`)
2. Parameter `prefix` diisi dengan nama awalan dari kolom-kolom baru yang akan dihasilkan
3. Fungsi ini akan mengembalikan dataframe baru yang berisi feature-feature numerik

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Teknik #2: One-hot Encoding (lanjutan)

	kerja_FREELANCE	kerja_PNS	kerja_SWASTA
0	0	0	1
1	0	1	0
2	0	1	0
3	1	0	0
4	0	1	0
5	0	0	1
6	1	0	0

Ketika kita tampilkan dataframe yang dihasilkan terlihat bahwa setiap nilai unik berubah menjadi kolom baru. Awalan nama kolom-kolom baru ini sesuai dengan isi parameter `prefix`.

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Data Besaran Penghasilan dari Survei Abhal^2 (encoded)

gender	pendidikan	kerja_freelance	kerja_PNS	kerja_swasta	penghasilan
0	1	0	0	1	7
0	0	0	1	0	13
1	1	0	1	0	15
0	2	1	0	0	24
1	3	0	1	0	17
1	1	0	0	1	23
1	0	1	0	0	12

Hore! Semua fitur sudah numerik!

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Rakamin Academy

Sudah.

Sesi tanya-jawab

Isi daftar hadir di sini!
bit.ly/RTCDS20DaftarHadir3

Rakamin Academy

Register Now, and Get Closer to Your Dream Job

Chat Data Science Admission Now!